

Proyectos de Redes Inalámbricas:

Tarea 8

Carlos Adolfo Calle García¹ and Joseph Mateo Jaramillo Gomez²

Universidad de Cuenca, Cuenca Av. 12 de Octubre, Ecuador
<https://www.ucuenca.edu.ec>

1 Desarrollo

1.1 Título

Segmentación Dinámica en el Borde para Reconocimiento Continuo de Actividades con CSI Wi-Fi

2 Objetivos

2.1 Objetivo General

Demostrar que el desacoplamiento de funciones en un sistema de reconocimiento continuo de actividades humanas (HAR) basado en señales Wi-Fi CSI permite optimizar el uso del ancho de banda sin degradar la precisión del reconocimiento, mediante una arquitectura híbrida *edge-server* que integre un mecanismo de segmentación dinámica en el borde (ESP32) y clasificación compleja con un modelo de aprendizaje profundo en un servidor local.

Versión alternativa: Elaborar una arquitectura híbrida Edge-Server para el Reconocimiento Continuo de Actividades Humanas (HAR) mediante señales Wi-Fi CSI, mediante la implementación de un algoritmo de segmentación dinámica en el nodo de borde, que habilite el procesamiento en tiempo real, optimice el uso del ancho de banda y permita la clasificación de actividades sin degradar la precisión del sistema.

2.2 Objetivos Específicos

1. Evaluar si la detección de intervalos de actividad dentro de un flujo de datos continuo en el borde es viable con recursos limitados y no introduce una latencia significativa, mediante el desarrollo de un algoritmo de segmentación dinámica basado en umbrales de varianza de la fase CSI sobre un microcontrolador ESP32.
2. Cuantificar la reducción del tráfico de red en comparación con el envío de la señal CSI cruda o con ventana fija mediante el desarrollo de un protocolo de comunicación ligero (MQTT o WebSockets) que transmita únicamente las ventanas de interés desde el ESP32 hacia el servidor.

3. Validar que la arquitectura de desacoplamiento mantiene la precisión en la detección de HAR mediante la implementación de un modelo de aprendizaje profundo (v.g., GAT o redes de tensores) en el servidor local y la comparación de métricas de desempeño frente a sistemas tradicionales de ventana fija.

3 Trabajos Relacionados y Estado del Arte

La evolución del *Human Activity Recognition* (HAR) basado en Wi-Fi ha alcanzado una madurez notable, con precisiones que superan el 95% en entornos controlados. No obstante, una revisión crítica de la literatura (resumida en la Tabla 1) revela que el despliegue en escenarios del mundo real enfrenta un "cuello de botella" crítico: la incapacidad de procesar flujos continuos de datos en dispositivos con recursos limitados sin comprometer la latencia o la precisión.

Actualmente, la comunidad científica aborda este desafío mediante dos enfoques con limitaciones operativas claras. Por un lado, trabajos fundamentales se centran en el "HAR Discreto", donde los segmentos de actividad son extraídos manualmente o mediante disparadores externos, eludiendo el problema de la segmentación dinámica en tiempo real [1], [2]. Por otro lado, propuestas recientes intentan capturar la complejidad de la señal mediante arquitecturas de "fuerza bruta" computacional, como redes de atención profunda, Transformers o modelos basados en la fusión de grafos y fase reconstruida [3], [4]. Si bien estos modelos logran una robustez superior ante el ruido, su demanda de memoria y capacidad de cómputo los hace inviables para una ejecución autónoma y continua en microcontroladores de bajo costo como el ESP32.

Incluso los avances en modelos ligeros, como el uso de reconstrucción de tensores de CSI [5], siguen dependiendo de que la señal de entrada sea representativa de una acción aislada. Esta dependencia crea una brecha en la literatura: la falta de una arquitectura que gestione el "caos temporal" de la señal continua antes de la clasificación.

Para resolver esta dicotomía, se propone un sistema híbrido que desacopla la detección de la clasificación. En lugar de exigir que una red neuronal procese la serie temporal completa, se implementa un filtro matemático ligero en el borde (*Edge*) basado en umbrales de varianza dinámica de la fase. Este componente actúa como un segmentador inteligente que identifica transiciones de interés, permitiendo que solo los segmentos relevantes sean procesados por modelos de clasificación robustos alojados en un servidor local. Este enfoque modular no solo reduce drásticamente el tráfico de red, sino que permite la implementación de modelos de vanguardia, como redes de atención o de grafos, sin las restricciones térmicas y de memoria del hardware de borde.

4 Hipótesis

La implementación de una arquitectura híbrida edge-server, fundamentada en un algoritmo de segmentación dinámica por varianza de fase ejecutado en un

Table 1. Matriz Comparativa de Investigaciones en HAR Basado en WiFi CSI (Actualizada)

Ref (Autor/Año)	Approach (Enfoque)	Methods (Modelos y DL)	Temporal Modeling & Segmentation	Findings	Limitations
Moshiri et al. (2021) [1]	HAR Discreto (7 actividades).	Conversión a RGB. 2D-CNN, 1D-CNN, LSTM y BLSTM con atención.	Captura de 20s. Extracción manual (3-6s) por video. BLSTM secuencial.	95.5% (2D-CNN); 94.7% (BLSTM).	Overfitting; distancia fija de 3m; LSTM sin info futura.
Yadav et al. (2022) [6]	HAR Discreto (Gestos multivariados).	CSTime. Estandarización de amplitud, Self-attention, activaciones Mish.	Series temporales multivariadas. Longitud estandarizada por mean-pooling.	Hasta 98.20%.	Caída en alta interferencia; datasets poco realistas.
Xu et al. (2025) [7]	HAR Discreto y gestos (SSL).	Benchmarking: MoCo, SwAV, MAE, ResNet, ViT.	Estandarización a duraciones fijas. ViT usa info temporal/canal.	98.03% (UT-HAR).	Problemas de domain shift; vulnerable a ataques.
Kang et al. (2025) [2]	HAR Discreto (Modelo Ligero para Edge).	GRU de capa única con módulo de atención, aumentación de datos y poda (pruning).	GRU extrae secuencias temporales univariadas/multivariadas evaluadas en cortes fijos.	98.92% (ARIL). Reducción masiva de parámetros.	Depende de datasets pre-segmentados; no aborda la segmentación dinámica.
Showmik et al. (2023) [8]	HAR Discreto (16 actividades).	Fusión de subportadoras (PCA), extracción (DWT) y 1D-CNN.	Segmentación adaptativa (ventana deslizante dinámica) basada en varianza.	95.5% a 97% (LOS).	Falla en actividades similares (tronco); baja al subir usuarios.
Islam et al. (2023) [3]	HAR Discreto (Espacial/Temporal).	STC-NLSTMNet: DS-Conv, FAM y Nested LSTM. Filtro Butterworth.	NLSTM para rasgos a largo plazo. Ventana deslizante (512, paso 128).	99.88% (Stan-WiFi).	Fallos en transiciones; pérdida de precisión a >3.7m por fading.
Wang et al. (2022) [9]	Estimación de Postura (Survey).	Modelos de esqueleto/contorno. PCA, DWT, Filtro Hampel.	Postura dinámica usa LSTM para relación temporal entre frames.	Variable (Mejor en estática).	Sensible a tasa de paquetes y acciones sutiles.
Ding y Wang (2019) [10]	HAR Discreto (6 actividades).	HARNN: RNN con bloques LSTM. TFA y CPV.	Detección por varianza (CPV). Periodos fijos de 15s. LSTM codifica tiempo.	96% promedio.	Requiere reentrenamiento total si cambia el entorno.
Chen et al. (2024) [5]	HAR Ligero y Generalizable.	Wisor-DL: Reconstrucción de tensores, GTCN y Dendrite Network.	GTCN para fusión de características temporales sobre tensores.	98.33% (UT-HAR). Eficiencia computacional.	Dependencia crítica de la precisión en la reconstrucción del tensor.
Chen et al. (2025) [4]	HAR por fusión de Fase y Grafos.	WiPhase: GPSiam (temporal) y DRGAT (subportadoras).	GPSiam captura dinámica temporal en integración de fase (CSI-PIR).	98.81% (UT-HAR). Alta robustez vía fase.	Complejidad en la eliminación de ruidos de fase (sanitización).

microcontrolador de recursos limitados (ESP32), permite el reconocimiento continuo de actividades humanas (HAR) mediante la reducción drástica del tráfico de datos redundantes hacia la red. Se teoriza que este desacoplamiento de funciones garantiza que el servidor local reciba únicamente intervalos con información cinemática relevante, habilitando el uso de modelos de aprendizaje profundo de alta densidad (v.g. GAT o redes de tensores) que mantendrán una precisión de clasificación superior al 95% y una latencia operativa mínima, superando las limitaciones de escalabilidad y saturación de los sistemas HAR tradicionales basados en ventanas fijas.

5 Metodología

La presente metodología propone un sistema de reconocimiento continuo de actividades (HAR) basado en el desacoplamiento de la detección y la clasificación, utilizando una arquitectura híbrida Edge-Server. Esta aproximación busca resolver el cuello de botella computacional al procesar flujos ininterrumpidos de datos. El flujo de trabajo secuencial de este diseño se muestra en la Fig. 1, estructurándose en cuatro fases principales descritas a continuación.

5.1 Adquisición y Segmentación Dinámica en el Borde (ESP32)

La primera etapa se ejecuta directamente en el dispositivo de borde (microcontrolador ESP32), el cual monitorea continuamente la señal Wi-Fi CSI. Para identificar de manera automática los intervalos de interés (movimiento) sin saturar la memoria limitada del hardware, se descarta el uso de algoritmos estadísticos iterativos o "batch" tradicionales, ya que requieren evaluar los datos de forma recursiva buscando el punto óptimo, lo que resulta computacionalmente insostenible para un microcontrolador.

En su lugar, la metodología adopta el enfoque propuesto por Showmik et al. [8], implementando un algoritmo de segmentación adaptativo basado en la varianza. El desafío de ingeniería de esta etapa consiste en adaptar y programar esta lógica matemática en C/C++ puro para operar en tiempo real. Esto implica la gestión eficiente de ventanas deslizantes y buffers circulares de memoria en el ESP32, permitiendo calcular los umbrales dinámicos al vuelo e identificar alteraciones significativas para recortar la señal, aislando el evento cinemático mientras se descartan los datos obsoletos.

5.2 Transmisión Optimizada de Datos

Una vez que el filtro en el ESP32 segmenta la transición de interés, el dispositivo descarta el ruido estático (periodos sin actividad) y empaqueta exclusivamente los datos útiles. Estos fragmentos son transmitidos al servidor local a través de protocolos ligeros de mensajería (como MQTT o WebSockets). Este paso reduce drásticamente el consumo de ancho de banda y evita el colapso de la red que ocurriría si se enviara la señal CSI cruda ininterrumpida.

5.3 Clasificación de Actividades en el Servidor (Deep Learning)

El procesamiento profundo y la clasificación de la actividad se delegan en su totalidad al servidor local. Al poseer más recursos, el servidor recibirá los segmentos pre-filtrados y aplicará sobre ellos arquitecturas robustas de Inteligencia Artificial.

Esta fase se sustenta metodológicamente en los avances de Azib et al. [11], quienes demuestran que aplicar redes profundas avanzadas (como CNNs para características locales, y LSTMs o GRUs para dependencias a largo plazo) e integrarlas mediante *Ensemble Learning* permite capturar las dependencias espacio-temporales del flujo de datos con altísima precisión. Asimismo, en concordancia con el trabajo de Khan & Roy [12], se justifica el uso de secuencias temporales procesadas a través de redes recurrentes (LSTM) para determinar con fiabilidad la existencia de eventos anómalos o acciones específicas dentro de una lectura de sensores. El uso de esta fuerza bruta computacional se vuelve viable en este proyecto precisamente porque el servidor ya no tiene que lidiar con horas de señal vacía.

5.4 Validación y Evaluación del Sistema en Flujos Continuos

Para garantizar una evaluación rigurosa y aislar las posibles fuentes de error, la validación del sistema no puede depender de una única métrica final, sino que se dividirá en dos etapas de evaluación independientes.

En primer lugar, para simular un escenario real ininterrumpido, se generará un flujo de datos continuo sintético concatenando segmentos de actividad provenientes de datasets estándar e intercalando periodos de "silencio" o ruido estático. Sobre este flujo, se medirá exclusivamente el rendimiento del algoritmo de segmentación en el ESP32. Dado que en series temporales continuas las métricas por punto penalizan injustamente los mínimos desfases, se adoptará la metodología de Tatbul et al. [13], utilizando Precisión y Recall basadas en rangos (*Range-based Precision and Recall*). Estas métricas cuantificarán de forma justa la recompensa de existencia (si el sistema logró detectar la actividad inyectada) y la recompensa de superposición (qué tan bien se alineó temporalmente el recorte del ESP32 con la ventana de movimiento real).

En segundo lugar, una vez comprobada la fidelidad geométrica y temporal de los recortes extraídos en la capa de borde, dichos fragmentos se utilizarán como entrada para el modelo de aprendizaje profundo en el servidor. El desempeño de esta fase de clasificación final se medirá utilizando métricas estándar como *Accuracy* y *F1-Score*, verificando si los segmentos filtrados retienen la información necesaria para una predicción exitosa.




Fig. 1. Flujo de trabajo secuencial propuesto para el HAR continuo utilizando una arquitectura híbrida Edge-Server y señales CSI de Wi-Fi.

Table 2. Cronograma de Implementación Híbrida HAR (Edge-Server)

Semana	Fechas	Fase	Actividad Específica	Entregable / Hito
Semana 1	27 Abr – 03 May	Edge	1.1 Configurar hardware (ESP32) y estructurar el algoritmo de varianza.	Script de captura base.
Semana 2	04 May – 10 May	Edge	1.2 Finalizar módulo de segmentación en C++ con ventanas deslizantes.	Algoritmo en C++ funcional.
Semana 3	11 May – 17 May	Edge	1.3 Evaluar la segmentación con flujos sintéticos usando métricas de rango.	M1: Segmentador Validado.
Semana 4	18 May – 24 May	Red	2.1 Implementar protocolo MQTT/WebSockets y lógica de empaquetado.	Enlace Edge-Server estable.
Semana 5	25 May – 31 May	Red	2.2 Validar la reducción del ancho de banda y latencia frente a envío crudo.	M2: Protocolo Optimizado.
Semana 6	01 Jun – 07 Jun	Server	3.1 Desplegar la arquitectura neuronal profunda (GAT/Tensores) en servidor.	Modelo DL operativo.
Semana 7	08 Jun – 14 Jun	Server	3.2 Integrar sistema End-to-End y evaluar clasificación (Accuracy, F1-Score).	M3: Clasificador Validado.
Semana 8	15 Jun – 21 Jun	Reporte	R.1 Sintetizar resultados, generar gráficas de desempeño y redactar borrador.	Borrador del documento.
Semana 9	22 Jun – 26 Jun	Cierre	R.2 Ajustes finales del reporte técnico y defensa del proyecto investigativo.	M4: Entrega Final (26 Jun).

6 Delimitación

El trabajo propuesto se limita al desarrollo y validación de una arquitectura híbrida (Edge-Server) para el reconocimiento de actividades. En el dispositivo de borde (microcontrolador ESP32), el alcance se limitará exclusivamente a la captura de la señal Wi-Fi CSI, la aplicación de un filtrado básico para mitigar el ruido estático, y la ejecución de un algoritmo de segmentación dinámica basado en varianza. Una vez extraídos los segmentos temporales de interés, se abarca la capa de red, donde estos serán empaquetados y transmitidos mediante un protocolo de mensajería ligero y de baja latencia (v.g., MQTT o WebSockets) hacia un servidor local. Posteriormente, el alcance de la clasificación recae enteramente en este servidor, el cual ejecutará los modelos de aprendizaje profundo para determinar la acción realizada. En cuanto a la evaluación, la inferencia se limitará al reconocimiento de un conjunto discreto de actividades cotidianas y transiciones físicas (tales como caminar, sentarse y levantarse), condicionadas por las clases del dataset de entrenamiento. Finalmente, para aislar el rendimiento de la arquitectura frente a variables incontrolables, los experimentos de validación se realizarán únicamente en escenarios de interior controlados, asumiendo condiciones de Línea de Visión Directa (Line of Sight) y la presencia de un único usuario activo, evitando así degradaciones por interferencia multiusuario o desvanecimiento multicamino extremo.

References

1. P. Fard Moshiri, R. Shahbazian, M. Nabati, and S. A. Ghorashi, "A CSI-based human activity recognition using deep learning," *Sensors*, vol. 21, no. 21, p. 7225, 2021.
2. H. Kang, D. Kim, and K.-A. Toh, "Human activity recognition through augmented WiFi CSI signals by lightweight Attention-GRU," *Sensors*, vol. 25, p. 1547, 2025.
3. M. S. Islam, M. K. A. Jannat, M. N. Hossain, W.-S. Kim, S.-W. Lee, and S.-H. Yang, "STC-NLSTMNet: An improved human activity recognition method using convolutional neural network with NLSTM from WiFi CSI," *Sensors*, vol. 23, no. 1, p. 356, 2023.
4. X. Chen, C. Li, C. Jiang, W. Meng, and W. Xiao, "WiPhase: A human activity recognition approach by fusing of reconstructed WiFi CSI phase features," *IEEE Transactions on Mobile Computing*, vol. 24, no. 1, pp. 394–405, 2025, dOI no disponible; añádelo cuando lo tengas.
5. X. Chen, Y. Zou, C. Li, and W. Xiao, "A deep learning based lightweight human activity recognition system using reconstructed WiFi CSI," *IEEE Transactions on Human-Machine Systems*, vol. 54, no. 1, pp. 68–78, 2024, dOI no disponible; añádelo cuando lo tengas.
6. S. K. Yadav, S. Sai, A. Gundewar, H. Rathore, K. Tiwari, H. M. Pandey, and M. Mathur, "CSITime: Privacy-preserving human activity recognition using WiFi channel state information," *Neural Networks*, vol. 146, pp. 11–21, 2022.
7. K. Xu, J. Wang, H. Zhu, and D. Zheng, "Evaluating self-supervised learning for WiFi CSI-based human activity recognition," *ACM Transactions on Sensor Networks*, vol. 21, no. 2, p. Article 21.
8. I. A. Showmik, T. F. Sanam, and H. Imtiaz, "Human activity recognition from Wi-Fi CSI data using principal component-based wavelet CNN," *Digital Signal Processing*, vol. 138, p. 104056, 2023.
9. Z. Wang, M. Ma, X. Feng, X. Li, F. Liu, Y. Guo, and D. Chen, "Skeleton-based human pose recognition using channel state information: A survey," *Sensors*, vol. 22, no. 22, p. 8738, 2022.
10. J. Ding and Y. Wang, "WiFi CSI-based human activity recognition using deep recurrent neural network," *IEEE Access*, vol. 7, pp. 174 257–174 269, 2019.
11. M. Azib, B. Renard, P. Garnier, V. Génot, and N. André, "Universal event detection in time series," *Preprint / Technical Report*, 2024, akkodis & Institut de Recherche en Astrophysique et Planétologie.
12. N. Khan and N. Roy, "Cooking event detection from temporal thermal condition of residential home," in *2020 IEEE International Conference on Pervasive Computing and Communications Workshops (PerCom Workshops)*, Mar. 2020.
13. N. Tatbul, T. J. Lee, S. Zdonik, M. Alam, and J. Gottschlich, "Precision and recall for time series," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 31, 2018. [Online]. Available: <https://arxiv.org/abs/1803.03639>